

LAPORAN AKHIR
PROYEK PENGANTI UAS

Mata Kuliah Kecerdasan Buatan
Semester Genap 2025/2026

Implementasi *Reinforcement Learning* Menggunakan *Q learning* pada Strategi Pertarungan *Pokemon Battle*

Subjudul: Reinforcement Learning

Disusun oleh:

Falah Andhesryo	NPM. 2306161990
Bonifasius Raditya Pandu Hendrianto	NPM. 2306242350
Christian Hadiwijaya	NPM. 2306161952
Jonathan Frederick Kosasih	NPM. 2306225981

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis, S.T., M.T., Ph.D.

DEPARTEMEN TEKNIK KOMPUTER

FAKULTAS TEKNIK

UNIVERSITAS INDONESIA

MEI 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas `metadata.json` yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI *assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Falah Andhesryo
NPM. 2306161990



()

Bonifasius Raditya Pandu Hendrianto
NPM. 2306242350



()

Christian Hadiwijaya
NPM. 2306161952



()

Jonathan Frederick Kosasih
NPM. 2306225981



()

DAFTAR ISI

Lembar Pernyataan Orisinalitas	1
Abstrak	6
1 PENDAHULUAN & DEFINISI MASALAH	7
1.1 Topik yang Dipilih	7
1.2 Rumusan Masalah	7
1.3 Tujuan Proyek	7
1.4 Ruang Lingkup & Batasan	8
2 PENDEKATAN AI	9
2.1 Tinjauan Pustaka	9
2.2 Landasan Teori Model yang Dipilih	10
2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI	13
2.3.1 <i>Tabular Q-Learning</i>	13
2.3.2 <i>Analisis Tradeoff</i>	14
2.3.3 Konteks Domain	14
2.4 Block Diagram Sistem <i>End-to-End</i>	15
2.5 <i>Flowchart</i> Program	16
3 IMPLEMENTASI & HASIL EKSPERIMEN	17
3.1 Dataset & Pra-pemrosesan	17
3.2 Konfigurasi Eksperimen	19
3.3 Metrik Evaluasi	21
3.4 Hasil Kuantitatif	21
3.5 Analisis <i>Hyperparameter Tuning</i>	22
3.6 Hasil Kualitatif & <i>Error Analysis</i>	24
3.7 Pembahasan	26
4 PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL	28
4.1 Falah Andhesryo – NPM. 2306161990	28
4.2 Bonifasius Raditya Pandu Hendrianto – NPM. 2306242350	28

4.3	Christian Hadiwijaya – NPM. 2306161952	29
4.4	Jonathan Frederick Kosasih – NPM. 2306225981	30
5	KESIMPULAN & PEKERJAAN LANJUTAN	31
5.1	Kesimpulan	31
5.2	Klaim Bonus Skor	31
5.3	Pekerjaan Lanjutan (<i>Future Work</i>)	32
	DAFTAR PUSTAKA	33
A	Berkas Metadata Proyek (JSON)	34
B	Tautan Repositori & Dataset	41
C	Research Participation Consent Form (<i>Informed Consent</i>)	42

DAFTAR GAMBAR

2.1	Arsitektur Q learning pada Pokemon Showdown	13
3.1	Grafik hasil <i>hyperparameter tuning</i> : sweep per parameter, ranking seluruh konfigurasi, kurva training, dan cakupan ruang state	23
3.2	Visualisasi analisis <i>Q-table</i> hasil <i>training</i>	24

DAFTAR TABEL

2.1	Ringkasan tinjauan pustaka	9
3.1	Komponen vektor state dan rentang nilainya	18
3.2	Pembagian episode pertarungan	18
3.3	Hyperparameter eksperimen	19
3.4	Parameter <i>reward shaping</i> dan nilai <i>default</i>	20
3.5	Spesifikasi hardware dan software	20
3.6	Metrik evaluasi yang digunakan	21
3.7	Perbandingan <i>win rate</i> terhadap paper acuan (Kalose et al.)	21
3.8	Detail hasil eksperimen proyek kami	21
3.9	Hasil lengkap <i>hyperparameter tuning</i>	22

ABSTRAK

Pertarungan *Pokemon battle* memiliki karakter pengambilan keputusan sekuensial karena setiap aksi yang dipilih pada satu giliran dapat memengaruhi kondisi pertarungan pada giliran berikutnya. Sistem ini menggunakan pendekatan *reinforcement learning* berbasis *tabular Q-learning* untuk melatih *agent* dalam memilih *move* terbaik pada simulator *Pokemon Showdown*. Data pengalaman diperoleh melalui interaksi langsung antara *agent* dan *environment*, dengan tim *agent* dibuat tetap dan tim lawan dipilih secara acak dari *custom opponent pool* berisi 50 *Pokemon Gen 1*. Representasi *state* dirancang sebagai tuple diskret 6 elemen yang mencakup *HP bucket* dan tipe *Pokemon* aktif, sedangkan *action* dibatasi pada pemilihan maksimal 4 *move* yang tersedia. *Reward* diberikan melalui kombinasi *terminal reward* untuk kemenangan atau kekalahan dan *modular reward shaping* yang mencakup komponen *damage*, *damage taken*, *KO*, *faint*, status kondisi, penalti waktu, dan *potential-based reward*. Pada konfigurasi *baseline*, *agent* mencapai *training win rate* 86,8%, *evaluation win rate* 94,8%, dan menemukan 9.772 *Q-table states*. Setelah dilakukan *hyperparameter tuning*, konfigurasi terbaik dengan $\alpha = 0.10$, $\gamma = 0.95$, dan $\lambda = 2.0$ mencapai *evaluation win rate* 96,8%. Hasil ini menunjukkan bahwa *tabular Q-learning* mampu membentuk strategi efektif pada ruang *state* dan *action* yang diskret, meskipun masih terbatas pada pemilihan *move* dan evaluasi terhadap *random opponent*.

Kata kunci: *reinforcement learning*, *Q-learning*, *Pokemon Showdown*, *Q-table*, *win rate*

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Topik yang dipilih adalah *reinforcement learning*. Topik ini dipilih karena memiliki karakteristik yang menarik dalam kajian *Artificial Intelligence (AI)*, terutama pada kemampuannya memodelkan proses *sequential decision-making*. Berbeda dari pendekatan yang hanya berfokus pada pengenalan pola, *reinforcement learning* menekankan bagaimana sebuah *agent* belajar menentukan *action* terbaik melalui interaksi dengan *environment* dan umpan balik berupa *reward*. Dalam laporan ini, pendekatan tersebut difokuskan pada metode *Q learning*, yaitu salah satu metode dasar dalam *reinforcement learning* yang memanfaatkan nilai *Q* untuk mengevaluasi kualitas suatu *action* pada kondisi tertentu. Karakteristik ini membuat topik *reinforcement learning* relevan untuk dianalisis karena mencakup konsep strategi, *exploration*, dan *adaptive learning* dalam sistem *AI* yang beroperasi pada situasi dinamis.

1.2 Rumusan Masalah

- RM1. Bagaimana konsep *reinforcement learning* diterapkan dalam proses pengambilan keputusan pada sistem berbasis *Q learning*?
- RM2. Bagaimana representasi *state*, *action*, dan *reward* digunakan dalam implementasi *Q learning* pada studi kasus *Pokemon battle*?
- RM3. Bagaimana hasil dan keterbatasan implementasi *Q learning* dalam membentuk strategi *agent* pada studi kasus *Pokemon battle*?

1.3 Tujuan Proyek

- T1. Menerapkan metode *Q learning* dengan eksplorasi *softmax* dalam skenario *Pokemon battle* menggunakan simulator *Pokemon Showdown* sebagai *environment*.
- T2. Merancang representasi *state*, *action*, dan *reward* yang sesuai untuk *agent* berbasis *tabular Q learning* pada domain *Pokemon battle* generasi pertama.
- T3. Mengevaluasi performa *agent* yang telah dilatih menggunakan metrik *win rate* terhadap lawan acak, serta membandingkan hasilnya dengan hasil pada paper acuan.
- T4. Menganalisis keterbatasan implementasi *tabular Q learning* pada domain *Pokemon battle*, termasuk cakupan ruang *state* dan pengaruh elemen stokastik simulator terhadap konvergensi kebijakan *agent*.

1.4 Ruang Lingkup & Batasan

Laporan ini berfokus pada perancangan, implementasi, dan analisis program *reinforcement learning* yang dikembangkan oleh tim. Program ini menggunakan metode *Q learning* untuk membentuk *agent* yang mampu mengambil keputusan dalam skenario *Pokemon battle*. Pembahasan mencakup konsep dasar *reinforcement learning*, perancangan *state*, *action*, dan *reward*, struktur program, proses *training*, proses *evaluation*, serta analisis terhadap hasil yang diperoleh dari implementasi program.

Batasan sementara yang digunakan dalam laporan ini adalah sebagai berikut.

- Program yang dianalisis merupakan produk utama yang dikembangkan oleh tim untuk menerapkan konsep *reinforcement learning* pada skenario permainan berbasis strategi.
- Metode yang digunakan dibatasi pada *tabular Q learning*, sehingga laporan ini tidak membahas metode *deep reinforcement learning* secara mendalam.
- Fokus pengembangan berada pada kemampuan *agent* dalam memilih *action* berdasarkan *state* dan *reward* yang diperoleh selama proses interaksi dengan *environment*.
- Ruang lingkup aksi *agent* dibatasi pada mekanisme yang telah diimplementasikan dalam program, sehingga strategi yang belum tersedia pada kode tidak menjadi fokus utama pembahasan.
- Analisis hasil dilakukan berdasarkan proses *training*, proses *evaluation*, dan performa program yang diperoleh dari implementasi yang telah dibuat.
- Laporan ini tidak membahas seluruh aspek teknis permainan secara mendalam, tetapi hanya aspek yang relevan dengan penerapan *reinforcement learning*.

BAB 2

PENDEKATAN AI

2.1 Tinjauan Pustaka

Tabel 2.1: Ringkasan tinjauan pustaka

Sumber	Metode	Dataset	Metrik/Hasil	Keterbatasan
GeeksforGeeks, <i>What is Reinforcement Learning</i> [1]	Teori Reinforcement Learning.	Tidak ada dataset spesifik. Penulis memakai lingkungan simulasi teoretis.	Agen berhasil memaksimalkan imbalan kumulatif.	Artikel ini hanya bersifat pengantar. Penulis tidak memberikan implementasi praktis.
AutoML.org, <i>Hyperparameter Tuning in Reinforcement Learning</i> [2]	Pencarian acak dan optimasi hiperparameter.	Lingkungan kontrol klasik dan robotika dasar.	Kinerja agen meningkat. Variasi pengaturan awal sangat mengubah hasil evaluasi.	Proses ini membutuhkan daya komputasi tinggi.
Jang et al., <i>Q-learning Algorithms: Classification and Applications</i> [3]	Tinjauan literatur algoritma Q learning.	Berbagai lingkungan permainan dan robotika.	Algoritma hibrida mengungguli metode Q learning dasar. Skalabilitas model terbukti meningkat.	Makalah ini berfokus pada teori. Peneliti tidak melakukan pengujian empiris baru.
Kalose, <i>Optimal Battle Strategy in Pokemon using Reinforcement Learning</i> [?]	Q learning dengan strategi eksplorasi dalam simulasi pertarungan Pokemon.	Simulator pertarungan Pokemon yang dibuat untuk eksperimen.	Agen berbasis Q learning mencapai <i>win rate</i> sekitar 65–70% terhadap lawan acak.	Lingkungan eksperimen masih lebih sederhana dibanding Pokemon Showdown karena tidak sepenuhnya merepresentasikan mekanika stokastik asli permainan.

lanjut ke halaman berikutnya

Tabel 2.1 - lanjutan

Sumber	Metode	Dataset	Metrik/Hasil	Keterbatasan
Park et al., <i>Distribution-Aware Reward</i> [4]	Regresi dengan imbalan sadar distribusi.	Kumpulan teks untuk evaluasi Model Bahasa Besar.	Model bahasa menghasilkan prediksi yang terkalibrasi. Keragaman teks keluaran tetap terjaga.	Kompleksitas waktu pelatihan model meningkat tajam.
Jha et al., <i>Deep Reinforcement Learning for Human Behavior</i> [5]	Pemodelan perilaku manusia berbasis jaringan saraf.	Data rekaman aktivitas harian manusia.	Model memprediksi tindakan manusia secara akurat.	Model rentan terhadap perubahan kebiasaan mendadak. Sistem sangat bergantung pada kualitas data masukan.
Keval, V., <i>Pokemon Showdown with Reinforcement Learning</i> [6]	Implementasi algoritma A2C pada permainan.	Lingkungan simulasi web Pokemon Showdown.	Agen berhasil mengalahkan pemain dasar. Pembentukan imbalan menentukan taktik permainan agen.	Agen masih kesulitan melawan strategi manusia yang kompleks.

Project ini berada pada irisan antara *Reinforcement Learning* tabular klasik dan *environment-driven decision making*. Secara umum, *reinforcement learning* mempelajari cara sebuah *agent* mengambil keputusan melalui interaksi dengan *environment* dan umpan balik berupa *reward* [1]. Berbeda dari studi *Reinforcement Learning* yang memanfaatkan jaringan saraf besar dan ruang *state* kontinu, proyek ini memakai representasi *state* diskret yang kecil sehingga pendekatan tabel masih memadai. Perbedaan utama dibanding implementasi Pokemon berbasis *reinforcement learning* pada paper Kalose adalah penggunaan Pokemon Showdown sebagai simulator yang lebih mendekati mekanika asli permainan, ruang aksi yang dibatasi pada aksi yang tersedia per giliran, dan *reward shaping* yang dibuat modular agar pengaruh setiap komponen dapat dianalisis secara terpisah [?].

2.2 Landasan Teori Model yang Dipilih

Reinforcement learning memodelkan pengambilan keputusan agen sebagai proses belajar dari interaksi dengan *environment*, yaitu ketika agen memilih aksi, menerima *reward*, lalu memperbaiki kebijakannya berdasarkan pengalaman tersebut [1]. Secara formal, proses ini dapat direpresentasikan sebagai *Markov*

Decision Process melalui elemen S (status), A (aksi), P (transisi), R (imbalan), dan γ (diskonto) untuk memaksimalkan total ekspektasi imbalan berikut:

Model yang digunakan pada proyek ini adalah *tabular Q learning*. *Q-learning* merupakan salah satu algoritma penting dalam keluarga *reinforcement learning* berbasis nilai karena mempelajari estimasi kualitas pasangan *state-action* melalui pembaruan nilai Q [3]. Pemilihan model ini sesuai dengan karakter lingkungan Pokemon Showdown yang memiliki keputusan diskrit, *feedback* berurutan, dan konsekuensi jangka panjang. Pada setiap *state* pertarungan, agen menyimpan nilai $Q(s, a)$ sebagai estimasi nilai jangka panjang dari memilih aksi a pada *state* s . Nilai ini diperbarui berdasarkan *reward* yang diterima pada langkah tersebut dan estimasi nilai *state* berikutnya.

$$Q_{\text{baru}}(s, a) = Q_{\text{lama}}(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q_{\text{lama}}(s, a)] \quad (2.1)$$

- s = status RL saat ini
- a = aksi pilihan agen
- r = imbalan setelah agen menjalankan aksi
- s' = status agen berikutnya
- α = tingkat pembelajaran agen (*learning rate*)
- γ = faktor diskonto (*discount factor*)
- $Q(s, a)$ meningkat saat agen menerima *reward*
- $Q(s, a)$ menurun saat agen mendapat penalti (tidak efektif)

State disini merupakan ringkasan kondisi pertarungan berisikan bucket HP aktif pemain, bucket HP aktif lawan, serta tipe utama dan tipe sekunder kedua Pokemon aktif. Representasi tersebut sengaja dibuat kecil agar tabel Q tetap terkelola, tetapi masih membawa informasi yang relevan terhadap pengambilan keputusan. Ruang aksi juga diskret karena pada satu giliran agen memilih salah satu move yang tersedia. Selain pembaruan Q , proses pemilihan aksi menggunakan eksplorasi *softmax*. Strategi eksplorasi semacam ini relevan dalam *reinforcement learning* karena performa agen sangat dipengaruhi oleh keseimbangan antara eksplorasi dan eksploitasi, serta oleh pemilihan *hyperparameter* yang sesuai [2]. Probabilitas memilih aksi a pada *state* s dituliskan sebagai:


$$\pi(a | s) = \frac{\exp(\lambda \hat{Q}(s, a))}{\sum_{b \in A(s)} \exp(\lambda \hat{Q}(s, b))} \quad (2.2)$$

- λ = parameter temperatur
- $\hat{Q}(s, a)$ = nilai Q yang telah dinormalisasi secara lokal pada aksi yang tersedia
- $A(s)$ = himpunan aksi yang valid pada *state* s

Untuk meningkatkan akurasi *training*, *reward* pada proyek ini tidak hanya berasal dari kemenangan atau kekalahan terminal, tetapi juga dari *shaping reward* per langkah. Desain *reward* menjadi penting karena sinyal imbalan menentukan arah pembelajaran agen dan dapat memengaruhi stabilitas maupun kualitas kebijakan yang terbentuk [4]. Secara konseptual, fungsi potensial yang digunakan ditulis sebagai:

$$F(s, s') = \gamma\Phi(s') - \Phi(s) \quad (2.3)$$

- $\Phi(s)$ = fungsi potensial yang merangkum kondisi strategis state



Gambar 2.1: Arsitektur Q learning pada Pokemon Showdown

Arsitektur model diatas tidak hanya mempelajari visual, teks, atau urutan token, melainkan juga mempelajari kebijakan keputusan dari ringkasan state yang telah didiskretkan. Alhasil proses belajar bersifat langsung dan sesuai dengan format keputusan turn-based.

$$\Phi(s) = w_{hp}(HP_{my}^{total} - HP_{opp}^{total}) + w_{alive}(alive_{my} - alive_{opp}) + w_{type} \cdot type_advantage(s) \quad (2.4)$$

- HP_{my}^{total} = total fraksi HP tim sendiri
- HP_{opp}^{total} = total fraksi HP tim lawan
- $alive_{my}$ = jumlah Pokemon sendiri yang masih hidup
- $alive_{opp}$ = jumlah Pokemon lawan yang masih hidup
- $type_advantage(s)$ = skor keuntungan tipe pada state tersebut

2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

2.3.1 Tabular Q-Learning

Sistem menggunakan *tabular Q-learning* karena sesuai dengan karakter masalah yang dihadapi, yakni:

- Ruang aksi pada masalah ini terbatas pada opsi manuver serangan (memilih salah satu move yang tersedia).
- Sistem meringkas representasi *state* menjadi sekumpulan data HP dan elemen tipe Pokemon
- Simulator Pokemon Showdown menyediakan interaksi online yang berulang, sehingga agen dapat belajar langsung dari pengalaman tanpa memerlukan dataset berlabel.

Pendekatan *Deep Reinforcement Learning* umumnya digunakan pada ruang *state* yang lebih kompleks dan sering memanfaatkan model jaringan saraf untuk mempelajari pola keputusan dari data berdimensi tinggi [5]. Sebaliknya, model tabel *Tabular Q Learning* mereduksi kompleksitas komputasi pada lingkungan dengan fitur terbatas dan diskret, sehingga lebih sesuai untuk desain *state* yang digunakan dalam proyek ini [3].

2.3.2 Analisis Tradeoff


Keputusan ini menyeimbangkan kapasitas model dengan kebutuhan data dan tingkat interpretasi.

- Model *Tabular Q Learning* berukuran sangat kecil dan berjalan ringan. Berbeda dengan model *deep learning* yang memetakan interaksi kompleks dengan mengorbankan kecepatan komputasi.
- Agen *Tabular Q Learning* belajar cepat melalui interaksi berulang, namun sistem ini mengeliminasi kebutuhan himpunan data berlabel dalam jumlah besar.
- Pembaruan nilai *Q* berjalan konstan dan stabil. Peneliti dapat menelusuri sumber keputusan agen langsung ke sel matriks tertentu.


2.3.3 Konteks Domain

Simulator ini memiliki mekanisme pertarungan bergiliran dengan opsi diskret. Atribut elemen tipe dan HP memberikan informasi yang solid bagi agen untuk memutuskan manuver dan keputusan selanjutnya. Lingkungan simulator menangani dinamika acak seperti serangan kritis atau tingkat akurasi secara independen. Arsitektur tabel mengeksekusi struktur keputusan diskrit ini dengan sangat optimal.

2.4 Block Diagram Sistem *End-to-End*



2.5 Flowchart Program



BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

Proyek ini tidak menggunakan dataset berlabel seperti pada pendekatan *supervised learning*. Seluruh data pengalaman dihasilkan langsung dari interaksi agen dengan lingkungan simulasi. Dengan kata lain, agen “membuat” datanya sendiri selama proses pelatihan, setiap keputusan yang diambil dan setiap hasil yang diterima menjadi sampel belajar bagi agen. Lingkungan simulasi yang dipakai adalah server lokal Pokemon Showdown versi *open-source*. Server ini menjalankan *logic* pertarungan Gen 1 (Kanto) secara utuh, mulai dari perhitungan *damage*, mekanika *healing move*, hingga interaksi *type effectiveness* antar Pokemon.

Sumber Data Pengalaman

Setiap episode pelatihan merepresentasikan satu pertandingan penuh dalam format `gen1ou`. Tim yang digunakan oleh agen bersifat tetap (*fixed team*) dan terdiri dari enam Pokemon tier OU Generasi 1: Alakazam, Snorlax, Tauros, Starmie, Exeggutor, dan Chansey. Keenam Pokemon ini dipilih berdasarkan *metagame* kompetitif Gen 1 karena memiliki *usage rate* tertinggi di format tersebut, sekaligus menyediakan cakupan tipe dan peran yang saling melengkapi.

Sementara itu, di sisi lawan, komposisi tim diacak ulang setiap pertandingan. Enam Pokemon dipilih secara *random sampling* dari *custom opponent pool* berisi 50 Pokemon Gen 1. Pool lawan ini di *generate* menggunakan *Generative AI* Claude Opus 4.6. Dengan pengacakan ini, agen terpapar pada puluhan ribu kemungkinan kombinasi tim lawan selama pelatihan berlangsung, sehingga kebijakan yang dipelajari bersifat general dan tidak tergantung pada komposisi lawan spesifik tertentu.

Representasi State (Pra-pemrosesan)

Agar ukuran Q-table tetap terkendali, informasi pertarungan pada setiap giliran diringkas menjadi vektor state berdimensi kecil. Proses pra-pemrosesan ini berjalan otomatis setiap kali agen diminta memilih aksi, dan terdiri dari dua langkah utama:

1. **Diskretisasi HP.** Fraksi HP Pokemon aktif (baik milik pemain maupun lawan) dipetakan ke dalam 10 *bucket* bernilai 0 sampai 9. Sebagai contoh, Pokemon yang masih memiliki 73% HP akan masuk ke bucket 7, sedangkan Pokemon dengan HP tersisa 5% masuk ke bucket 0. Pendekatan ini secara efektif memampatkan ruang kontinu HP menjadi representasi diskret tanpa mengorbankan informasi kondisi pertarungan secara signifikan.
2. **Ekstraksi tipe.** Tipe primer dan tipe sekunder dari kedua Pokemon aktif (milik pemain dan lawan) dicatat sebagai fitur kategorikal. Dalam Gen 1 terdapat 15 tipe unik, dan informasi ini menjadi dasar

bagi agen untuk memperkirakan efektivitas serangan. Pokemon yang hanya memiliki satu tipe diberi label “NONE” pada slot tipe sekunder.

Hasil pra-pemrosesan berupa tuple 6-elemen:

$(player_hp_bucket, opp_hp_bucket, player_type_1, player_type_2, opp_type_1, opp_type_2)$.

Tuple ini menjadi kunci unik pada Q-table. Dengan desain ini, ruang state yang mungkin secara teoritis adalah $10 \times 10 \times 15 \times 16 \times 15 \times 16 = 5.760.000$ kombinasi, namun dalam praktiknya hanya sebagian kecil yang benar-benar ditemui selama pelatihan (sekitar 9.000–10.000 state unik).

Tabel 3.1: Komponen vektor state dan rentang nilainya

Fitur	Tipe Data	Keterangan
<code>player_hp_bucket</code>	Integer (0–9)	HP Pokemon aktif pemain, didiskretisasi per 10%
<code>opp_hp_bucket</code>	Integer (0–9)	HP Pokemon aktif lawan, didiskretisasi per 10%
<code>player_type_1</code>	Kategorikal	Tipe primer Pokemon aktif pemain (15 tipe Gen 1)
<code>player_type_2</code>	Kategorikal	Tipe sekunder pemain, atau “NONE” jika mono-type
<code>opp_type_1</code>	Kategorikal	Tipe primer Pokemon aktif lawan
<code>opp_type_2</code>	Kategorikal	Tipe sekunder lawan, atau “NONE”

Pembagian Episode Pelatihan dan Evaluasi

Karena Q learning bersifat *online*, tidak ada pembagian *train/validation/test* seperti pada *supervised learning*. Agen belajar secara langsung dari setiap pertandingan yang dijalankan. Evaluasi dilakukan terpisah setelah fase pelatihan selesai: agen menjalankan *greedy rule* (tanpa eksplorasi) melawan lawan-lawan baru yang komposisi timnya belum tentu pernah ditemui saat pelatihan.

Tabel 3.2: Pembagian episode pertarungan

Fase	Jumlah Pertarungan	Keterangan
Pelatihan	8.000	Agen belajar dengan eksplorasi <i>softmax</i> ; Q-table diperbarui setiap giliran
Evaluasi	500	Kebijakan <i>greedy</i> ($\arg \max_a Q(s, a)$); lawan acak baru
Total	8.500	Per konfigurasi hyperparameter

Jumlah 8.000 episode pelatihan dipilih agar Q-table memiliki cukup waktu untuk mengeksplorasi variasi *matchup* yang luas sebelum konvergen. Berdasarkan observasi, kurva *win rate* umumnya mulai stabil setelah episode ke-3.000, sehingga 8.000 episode memberikan margin yang memadai. Evaluasi menggunakan 500 pertandingan karena sudah memberikan estimasi *win rate* yang stabil dengan standar deviasi

yang kecil. Seed acak untuk pemilihan tim lawan dikelola oleh modul `random` Python dan library `numpy`. Pengacakan tim lawan bersifat disengaja dan merupakan bagian dari desain eksperimen.

3.2 Konfigurasi Eksperimen

Metode yang digunakan adalah *tabular Q learning* dengan eksplorasi *softmax*. Karena pendekatan ini bersifat *online* dan berbasis tabel (bukan *neural network*), tidak ada konsep *batch size*, *optimizer*, maupun *scheduler* seperti pada *deep learning*. Pembaruan Q-value dilakukan langsung setiap giliran (*turn*) dalam pertarungan.

Hyperparameter

Tabel 3.3: Hyperparameter eksperimen

Parameter	Nilai	Keterangan
α (<i>learning rate</i>)	0.10	Seberapa besar Q-value diperbarui tiap <i>step</i>
γ (<i>discount factor</i>)	0.95	Bobot <i>future reward</i> terhadap <i>immediate reward</i>
λ (<i>softmax temperature</i>)	1.0	Mengontrol tingkat eksplorasi vs eksploitasi
Jumlah episode pelatihan	8.000	Satu episode = satu pertandingan utuh
Jumlah episode evaluasi	500	<i>greedy rule</i> , tanpa eksplorasi

Fungsi Reward

Agen menerima *reward* pada dua kondisi utama:

1. **Terminal reward** (diberikan saat pertarungan berakhir):

- Menang: +100
- Kalah: -100

2. **Intermediate reward** (diberikan setiap giliran selama pertandingan berlangsung). Berbeda dari pendekatan sederhana yang hanya memakai selisih HP, fungsi reward per giliran dirancang secara modular dengan beberapa komponen terpisah:

$$r_t = r_{\text{damage}} + r_{\text{taken}} + r_{\text{KO}} + r_{\text{faint}} + r_{\text{status}} + r_{\text{time}} + r_{\text{potential}} \quad (3.1)$$

Masing-masing komponen dihitung sebagai berikut:

- $r_{\text{damage}} = k_d \cdot \Delta \text{HP}_{\text{opp}}$: bonus sebanding dengan fraksi HP yang berhasil dikurangi dari Pokemon lawan ($k_d = 40.0$)
- $r_{\text{taken}} = -k_t \cdot \Delta \text{HP}_{\text{my}}$: penalti sebanding dengan fraksi HP yang hilang dari Pokemon sendiri ($k_t = 30.0$)
- $r_{\text{KO}} = K_{\text{bonus}} \cdot n_{\text{KO}}$: bonus setiap berhasil membuat Pokemon lawan *faint* ($K_{\text{bonus}} = 20.0$)

- $r_{\text{faint}} = -F_{\text{penalty}} \cdot n_{\text{faint}}$: penalti setiap Pokemon sendiri *faint* ($F_{\text{penalty}} = 20.0$)
- $r_{\text{status}} = S_{\text{bonus}} \cdot n_{\text{status}}$: bonus kecil saat berhasil memberi *status condition* pada lawan ($S_{\text{bonus}} = 5.0$)
- $r_{\text{time}} = -0.1$: penalti waktu konstan per giliran untuk mendorong permainan yang lebih cepat
- $r_{\text{potential}} = \gamma\Phi(s') - \Phi(s)$: *potential-based reward shaping* (lihat Persamaan 2.4)

Seluruh *intermediate reward* di-clip ke rentang $[-50, +50]$ agar tidak mendominasi sinyal *terminal reward* (± 100). Desain ini memungkinkan agen mendapat *feedback* di setiap giliran, tidak hanya soal besarnya damage, tetapi juga tentang kondisi pertarungan secara keseluruhan.

Tabel 3.4: Parameter *reward shaping* dan nilai *default*

Parameter	Nilai	Peran
k_d (<i>damage reward</i>)	40.0	Skala bonus damage ke lawan
k_t (<i>taken penalty</i>)	30.0	Skala penalti damage diterima
K_{bonus} (<i>KO bonus</i>)	20.0	Bonus per KO lawan
F_{penalty} (<i>faint penalty</i>)	20.0	Penalti per Pokemon sendiri faint
S_{bonus} (<i>status bonus</i>)	5.0	Bonus memberi status ke lawan
<i>time penalty</i>	0.1	Penalti konstan per giliran
w_{hp}	1.0	Bobot selisih HP dalam fungsi potensial
w_{alive}	8.0	Bobot selisih jumlah Pokemon hidup
w_{type}	2.0	Bobot keuntungan tipe aktif

Asimetri antara $k_d = 40$ dan $k_t = 30$ disengaja: agen sedikit lebih dihargai saat menyerang dibanding dihukum saat diserang, untuk mendorong perilaku agresif yang sesuai dengan format Gen 1 OU yang cenderung ofensif. Sementara itu, $w_{\text{alive}} = 8.0$ yang jauh lebih besar dari w_{hp} dan w_{type} mencerminkan bahwa menjaga jumlah Pokemon hidup merupakan faktor strategis paling penting dalam pertarungan 6-vs-6.

Hardware dan Framework

Tabel 3.5: Spesifikasi hardware dan software

Komponen	Detail
Prosesor	Intel Core i7 Gen-13 (laptop)
GPU	— (tidak digunakan)
Framework	<code>poke-env</code> $\geq 0.15.0$, <code>numpy</code> $\geq 1.24.0$
Simulator	Pokemon Showdown (server lokal, Node.js)
Bahasa	Python 3.11
Durasi training	≈ 1.006 detik (~ 17 menit) untuk 8.000 pertarungan

Karena Q learning tabular hanya menyimpan dan membaca nilai dari *dictionary*, seluruh komputasi berjalan di CPU tanpa memerlukan akselerasi GPU. Durasi training didominasi oleh overhead komunikasi antara agen Python dan server Pokemon Showdown via *websocket*.

3.3 Metrik Evaluasi

Dalam konteks *reinforcement learning* untuk permainan, metrik utama yang paling relevan adalah *win rate*. Metrik ini dipilih karena tujuan akhir agen memang memenangkan pertarungan, bukan sekadar memaksimalkan *reward* kumulatif (agen bisa saja mendapat banyak *intermediate reward* tapi tetap kalah di akhir).

Tabel 3.6: Metrik evaluasi yang digunakan

Metrik	Fase	Justifikasi
<i>Win rate</i> (evaluasi)	Evaluasi	Metrik utama; mengukur seberapa baik kebijakan yang sudah dipelajari ketika dijalankan secara <i>greedy</i> tanpa eksplorasi
<i>Win rate</i> (training)	Pelatihan	Indikator konvergensi; apakah agen membaik seiring bertambahnya episode
Jumlah <i>Q-table states</i>	Pelatihan	Mengukur seberapa luas ruang state yang berhasil dieksplorasi agen selama pelatihan

Win rate evaluasi dihitung setelah pelatihan selesai, menggunakan aturan *greedy* ($\arg \max_a Q(s, a)$) melawan lawan acak yang timnya mungkin tidak pernah ditemui saat pelatihan. Ini memastikan metrik mencerminkan kemampuan generalisasi, bukan sekadar hafalan terhadap lawan tertentu.

3.4 Hasil Kuantitatif

Tabel berikut merangkum performa agen kami dan membandingkannya dengan hasil dari paper acuan Kalose, Kaya, & Kim yang menggunakan pendekatan serupa (Q learning dengan *softmax* dan *epsilon-greedy*) namun pada simulator deterministik buatan sendiri dengan tim acak di **kedua** sisi.

Tabel 3.7: Perbandingan *win rate* terhadap paper acuan (Kalose et al.)

Metode	Kondisi	Paper Acuan	Proyek Kami
Softmax (5.000 games)	vs Random	65%	94,8%
Softmax (20.000 games)	vs Random	70%	—

Tabel 3.8: Detail hasil eksperimen proyek kami

Metrik	Nilai
<i>Win rate</i> training (8.000 battles, softmax)	86,8% (6.941 W / 1.059 L)
<i>Win rate</i> evaluasi (500 battles, greedy)	94,8% (474 / 500)
Jumlah Q-table states yang ditemukan	9.772
Durasi training	1.005,5 detik

Beberapa hal yang bisa dilihat dari perbandingan di atas:

- Dengan jumlah episode yang sebanding (8.000 vs 5.000), *win rate* evaluasi kami (94,8%) jauh melampaui paper acuan (65%). Perbedaan utama terletak pada desain eksperimen: paper acuan menggunakan

tim acak di **kedua sisi** (agen dan lawan sama-sama random team), sementara proyek kami meng-*fix* tim agen dengan 6 Pokemon OU terbaik Gen 1. Ini memberi keuntungan besar karena agen hanya perlu belajar strategi untuk satu komposisi tim yang sudah kuat secara *metagame*.

- *Win rate* evaluasi (94,8%) lebih tinggi dari training (86,8%) karena saat evaluasi agen murni *greedy* dan tidak lagi mengeksplorasi *move* suboptimal.
- Paper acuan juga menggunakan simulator deterministik (tanpa *miss chance*, tanpa *critical hit*), sedangkan kami menggunakan Pokemon Showdown yang mensimulasikan *battle* Gen 1 secara penuh termasuk elemen stokastik. Meskipun demikian, keunggulan tim yang sudah di-*fix* dan desain *reward shaping* modular tampaknya lebih dominan pengaruhnya.
- Jumlah 9.772 state menunjukkan ruang state masih cukup kecil untuk *tabular* Q learning, konvergensi tercapai tanpa memerlukan *function approximation*.

3.5 Analisis Hyperparameter Tuning

Proses *hyperparameter tuning* dilakukan dengan pendekatan *grid search* satu dimensi (*one-at-a-time sweep*), yaitu memvariasikan satu parameter pada satu waktu sambil mengunci parameter lainnya pada nilai *baseline*. Parameter yang diuji adalah *learning rate* (α), *discount factor* (γ), dan temperatur *softmax* (λ). Setiap konfigurasi dijalankan dengan 8.000 episode pelatihan dan 500 episode evaluasi *greedy*. Parameter *reward shaping* (k_d , k_t , w_{hp} , w_{alive} , w_{type} , dan sebagainya) dikunci pada nilai *default* di seluruh percobaan agar pengaruh masing-masing parameter dapat diisolasi.

Tabel 3.9: Hasil lengkap *hyperparameter tuning*

ID	α	γ	λ	Train%	Eval%	States
lam_2.0	0.10	0.95	2.0	90,4%	96,8%	9.459
gamma_0.99	0.10	0.99	1.0	86,1%	96,8%	9.742
gamma_0.90	0.10	0.90	1.0	86,4%	96,4%	9.807
lam_5.0	0.10	0.95	5.0	92,9%	96,2%	8.933
lam_0.5	0.10	0.95	0.5	82,9%	96,0%	9.977
alpha_0.05	0.05	0.95	1.0	87,5%	96,0%	9.738
baseline	0.10	0.95	1.0	86,8%	94,8%	9.772
gamma_0.80	0.10	0.80	1.0	86,6%	94,8%	9.833
alpha_0.20	0.20	0.95	1.0	86,1%	93,2%	9.808
alpha_0.30	0.30	0.95	1.0	84,0%	93,0%	9.847

Temperatur *softmax* (λ) adalah parameter paling berpengaruh. Kenaikan dari $\lambda = 1.0$ ke $\lambda = 2.0$ meningkatkan *eval win rate* dari 94,8% menjadi 96,8% sekaligus menaikkan *training win rate* dari 86,8% menjadi 90,4%, menjadikannya konfigurasi terbaik secara keseluruhan. Pada $\lambda = 5.0$, eksplorasi yang terlalu kecil mulai mengurangi generalisasi (*eval* turun ke 96,2%), sedangkan $\lambda = 0.5$ tetap kompetitif di 96,0% berkat keluasan eksplorasi meski *training win rate*-nya terendah (82,9%). Secara keseluruhan, temuan ini menunjukkan bahwa *baseline* masih terlalu banyak mengeksplorasi aksi suboptimal, dan menaikkan λ memperbaiki hal tersebut.

Discount factor (γ) menempati posisi kedua. Nilai $\gamma = 0.99$ menghasilkan *eval win rate* 96,8%, setara konfigurasi terbaik, karena agen lebih mempertimbangkan *reward* jangka panjang yang sesuai dengan durasi pertarungan 10–20 giliran. Sebaliknya, $\gamma = 0.80$ menurun ke 94,8% akibat *myopic behavior*: agen kurang menghargai kemenangan di akhir pertarungan yang panjang.

Learning rate (α) adalah parameter paling tidak sensitif. Nilai $\alpha = 0.05$ memberikan 96,0% karena pembaruan konservatif lebih stabil terhadap elemen stokastik Gen 1, sedangkan $\alpha = 0.20$ dan $\alpha = 0.30$ justru menurunkan performa ke 93,2% dan 93,0% karena Q-value menjadi terlalu reaktif terhadap hasil pertarungan yang tidak representatif akibat RNG.

Urutan sensitivitas hyperparameter dari yang paling ke paling tidak berpengaruh adalah: $\lambda > \gamma > \alpha$. Rentang *eval win rate* yang dicakup oleh masing-masing sweep adalah: λ menghasilkan rentang 96,0%–96,8%; γ menghasilkan 94,8%–96,8%; α menghasilkan 93,0%–96,0%. Menariknya, semua konfigurasi yang diuji tetap menghasilkan *eval win rate* di atas 93%, yang mengindikasikan bahwa robustness performa lebih banyak berasal dari kekuatan tim *fixed* OU Gen 1 daripada dari sensitivitas hyperparameter itu sendiri.




Gambar 3.1: Grafik hasil *hyperparameter tuning*: sweep per parameter, ranking seluruh konfigurasi, kurva training, dan cakupan ruang state

3.6 Hasil Kualitatif & Error Analysis


Secara umum, *win rate* training seluruh konfigurasi menunjukkan tren peningkatan yang konsisten. Pada 500 pertarungan pertama, *win rate* agen berada di kisaran 60–70% karena *Q-table* belum terisi dan agen masih sangat bergantung pada eksplorasi acak. Memasuki pertarungan ke-1.000 hingga ke-2.000, kenaikan paling curam terjadi karena agen mulai mengakumulasi state yang sering ditemui dan nilai *Q* mulai konvergen. Setelah pertarungan ke-3.000, kurva melandai dan *win rate* training stabil di kisaran 84–93% bergantung pada konfigurasi.

Analisis Visualisasi *Q-table*


Selain melihat *win rate*, perilaku *agent* juga dianalisis melalui visualisasi nilai pada *Q-table*. Visualisasi ini digunakan untuk melihat bagaimana nilai *Q* tersebar setelah proses *training*, apakah *agent* cenderung memilih indeks aksi tertentu, serta seberapa besar variasi nilai maksimum *Q* pada setiap *state*.




(a) Rata-rata nilai *Q* per indeks aksi



(b) Distribusi nilai *Q*



(c) Sebaran *state value*



(d) Distribusi aksi terbaik per *state*

Gambar 3.2: Visualisasi analisis *Q-table* hasil *training*.

Gambar 3.2 menunjukkan bahwa nilai *Q* tidak tersebar secara merata pada seluruh indeks aksi. Rata-rata nilai *Q* tertinggi muncul pada indeks aksi 0, disusul oleh indeks aksi 3, sedangkan indeks aksi 2 memiliki rata-rata nilai *Q* paling rendah. Pola ini menunjukkan bahwa selama proses *training*, *agent* lebih sering menemukan nilai strategis yang tinggi pada indeks aksi tertentu. Namun, karena indeks aksi merepresentasikan urutan *move* yang tersedia pada setiap kondisi pertarungan, hasil ini tidak dapat langsung dimaknai sebagai satu jenis *move* tertentu.

Distribusi nilai Q memperlihatkan bahwa sebagian besar nilai berada di sekitar nol, dengan beberapa nilai positif tinggi sebagai *outlier*. Hal ini menunjukkan bahwa banyak pasangan *state-action* masih memiliki nilai rendah atau belum sering dikunjungi, sedangkan sebagian kecil pasangan *state-action* memperoleh nilai tinggi karena sering menghasilkan kondisi yang menguntungkan. Sebaran *state value* juga memperkuat temuan ini karena mayoritas *state* memiliki nilai maksimum Q yang relatif rendah hingga sedang, sementara beberapa *state* memiliki nilai maksimum yang jauh lebih tinggi.

Distribusi aksi terbaik per *state* menunjukkan bahwa *agent* tidak hanya bergantung pada satu indeks aksi. Indeks aksi 0 memang paling sering menjadi aksi terbaik, tetapi indeks aksi 1 dan 3 juga muncul dalam jumlah yang cukup besar. Hal ini menunjukkan bahwa *policy* yang terbentuk tetap bervariasi mengikuti kondisi *state*, bukan sekadar memilih satu aksi yang sama pada seluruh kondisi pertarungan.

Contoh Kasus Keputusan Benar

1. **Memanfaatkan *type advantage* melawan Pokemon Air.** Ketika agen menghadapi Starmie lawan (Water/Psychic) dengan kondisi HP setara, agen yang telah dilatih secara konsisten memilih *Thunderbolt* milik Starmie tim sendiri daripada *Surf*. Nilai Q untuk aksi *Thunderbolt* pada state (`bucket_hp=5, opp_bucket=5, Water, Psychic, Water, Psychic`) jauh lebih tinggi karena sinyal *potential-based reward* menangkap keuntungan tipe listrik terhadap air.
2. **Menggunakan *recovery move* saat HP kritis.** Pada state dengan `player_hp_bucket=1` (HP $\leq 10\%$), agen cenderung memilih *Recover/Rest* jika tersedia, daripada menyerang. Pola ini konsisten dengan reward shaping yang menghukum selisih HP negatif secara berkelanjutan.
3. **Mempertahankan keunggulan HP.** Ketika lawan sudah lemah (`opp_hp_bucket=1`), agen secara konsisten memilih serangan dengan damage tertinggi (misalnya *Hyper Beam* atau *Psychic*) untuk mengakhiri pertarungan secepat mungkin, yang sesuai dengan tingginya nilai Q pada aksi agresif di state tersebut.

Contoh Kasus Kegagalan

1. **Gagal menangani *sleep* dan status kondisi.** Ketika Pokemon agen terkena *Sleep Powder* atau *Hypnosis*, state yang direpresentasikan tidak mencakup informasi status kondisi. Akibatnya, agen terus memilih move seperti biasa tanpa menyadari bahwa Pokemon aktifnya tidak bisa bergerak, sehingga giliran terbuang sia-sia. Kasus ini ditemukan berulang saat menghadapi Exeggutor atau Jynx lawan.

Hipotesis: Absennya fitur status kondisi (tidur, lumpuh, keracunan) dalam representasi state menyebabkan agen tidak memiliki mekanisme untuk merespons situasi tersebut. *Mitigasi yang dapat dicoba:* menambahkan fitur biner status kondisi Pokemon aktif ke dalam tuple state.

2. **Keputusan suboptimal ketika nilai Q hampir seragam.** Pada state yang jarang ditemui selama pelatihan (terutama kombinasi tipe langka seperti Ghost atau Dragon), Q-table memiliki nilai yang hampir seragam untuk semua aksi karena jarang diperbarui. Akibatnya, agen memilih aksi secara *near-random*, termasuk menggunakan *Night Shade* pada Pokemon Normal yang imun terhadapnya.

Hipotesis: Kurangnya kunjungan pada state langka menyebabkan estimasi Q yang tidak akurat. Jumlah 9.000–10.000 state yang ditemukan memang mencakup sebagian besar kondisi umum, tetapi kombinasi tipe yang jarang tetap tidak terepresentasi dengan baik. *Mitigasi yang dapat dicoba:* meningkatkan jumlah episode pelatihan untuk state langka, atau menambahkan *optimistic initialization* pada Q-table.

3. **Tidak melakukan *switch* secara strategis.** Implementasi saat ini membatasi aksi agen hanya pada pemilihan *move*, tanpa opsi *switch* Pokemon sebagai bagian dari ruang aksi yang dipelajari. Akibatnya, agen tidak dapat keluar dari *type disadvantage* secara eksplisit. Sebagai contoh, ketika Snorlax agen menghadapi Machop lawan (Fighting), agen tidak memiliki pilihan untuk *switch* ke Starmie atau Alakazam yang lebih menguntungkan.

Hipotesis: Pembatasan ruang aksi ini merupakan batasan desain yang disengaja untuk menjaga *state space* tetap kecil. Meskipun *potential-based reward* secara implisit mendorong *switch* melalui komponen w_{type} , mekanisme ini tidak cukup untuk menggantikan *switch* eksplisit. *Mitigasi yang dapat dicoba:* memperluas ruang aksi untuk menyertakan aksi *switch* dengan representasi state yang diperluas.

Dari 500 pertarungan evaluasi pada konfigurasi terbaik ($lam_2.0$), agen memenangkan 484 pertarungan dan kalah pada 16 pertarungan, menghasilkan *eval win rate* 96,8%. Kekalahan terkonsentrasi pada skenario di mana lawan memiliki Pokemon dengan *sleep-inducing move* (Exeggutor, Jynx, Venusaur) atau ketika agen secara tidak beruntung terkena serangkaian *critical hit* berturut-turut. Kedua skenario ini berkaitan dengan elemen stokastik simulator yang tidak dapat sepenuhnya diantisipasi oleh representasi state yang ada.

3.7 Pembahasan

RM1: Konsep *reinforcement learning* berhasil diterapkan secara penuh melalui siklus interaksi agen–lingkungan yang berlangsung online. Agen mengobservasi state, memilih aksi berdasarkan kebijakan *softmax*, dan memperbarui Q-table menggunakan persamaan Bellman setiap giliran. Pelatihan selama 5.000 episode menghasilkan Q-table dengan 9.000–10.000 state unik, menunjukkan eksplorasi yang memadai tanpa kebutuhan *function approximation*.

RM2: Representasi state berbasis enam fitur (bucket HP pemain, bucket HP lawan, dua tipe pemain, dua tipe lawan) terbukti cukup untuk memandu kebijakan yang efektif. Ruang aksi yang dibatasi pada pemilihan *move* (maksimum 4 aksi per giliran) memungkinkan Q-table tetap terkelola. Desain *reward* berlapis (terminal reward ± 100 ditambah *intermediate reward* berbasis selisih HP dan *potential-based shaping*) memberikan sinyal pembelajaran yang kaya setiap giliran tanpa membalikkan prioritas utama memenangkan pertarungan.

RM3: Agen mencapai *eval win rate* hingga 96,8% terhadap lawan acak, melampaui hasil paper acuan Kalose et al. yang melaporkan 65% pada jumlah episode yang sama. Keterbatasan utama yang diidentifikasi adalah: (1) tidak adanya mekanisme *switch* Pokemon dalam ruang aksi; (2) absennya fitur status kondisi dalam representasi state; dan (3) estimasi Q yang lemah pada state langka.

Hasil proyek ini secara kuantitatif melampaui paper acuan Kalose et al. (96,8% vs 65% pada 5.000 episode). Namun perlu dicatat bahwa perbandingan ini tidak sepenuhnya *apple-to-apples*: paper acuan menggunakan tim acak di kedua sisi, sementara proyek ini menggunakan tim tetap OU Gen 1 untuk agen. Keunggulan ini disumbangkan oleh tiga faktor: (1) tim tetap yang secara metagame sudah optimal mengurangi kompleksitas kebijakan yang perlu dipelajari; (2) *reward shaping* berbasis potensi memberikan sinyal yang lebih informatif dibanding reward terminal saja; (3) jumlah state yang relatif kecil (~9.000–10.000) memungkinkan konvergensi yang lebih cepat.

Dibandingkan dengan pendekatan *deep RL* pada Pokemon Showdown seperti yang diulas oleh Vivek Keval et al., pendekatan tabular ini lebih mudah dianalisis dan direproduksi, meskipun tidak dapat menskalakan ke ruang state yang lebih besar. Temuan bahwa λ dan γ lebih berpengaruh daripada α juga konsisten dengan observasi umum pada literatur sensitivitas hyperparameter RL (AutoML.org), yang menyebutkan bahwa parameter eksplorasi dan *horizon* sering kali lebih kritis daripada kecepatan pembaruan pada lingkungan berdimensi rendah.

Keterbatasan Eksperimen

- **Tidak ada mekanisme *switch*.** Ruang aksi yang dibatasi hanya pada *move* menyebabkan agen tidak dapat merespons *type disadvantage* secara eksplisit. Hal ini merupakan penyederhanaan yang disengaja, tetapi membatasi kemampuan generalisasi terhadap strategi pertarungan yang lebih kompleks.
- **Representasi state yang terbatas.** Fitur status kondisi (tidur, lumpuh, *burn*, *freeze*), momentum serangan, dan informasi *moveset* lawan tidak dimasukkan ke dalam state. Akibatnya, agen berperilaku identik terlepas dari apakah Pokemon aktifnya sedang tertidur atau sehat.
- **Lawan yang terbatas pada *RandomPlayer*.** Evaluasi hanya dilakukan terhadap lawan yang memilih aksi secara acak. Performa agen terhadap lawan yang lebih strategis (misalnya agen Q learning lain atau pemain manusia) belum diukur, sehingga tingkat generalisasi sebenarnya sulit dinilai.
- **Satu kali *run* per konfigurasi.** Karena elemen stokastik simulator, hasil satu *run* per konfigurasi rentan terhadap variasi acak. Idealnya, setiap konfigurasi dijalankan minimal tiga kali dengan seed berbeda untuk memperoleh estimasi *win rate* yang lebih stabil.
- **Pool lawan yang diperluas belum diuji.** Setelah perluasan *pool* lawan dari 30 menjadi 50 Pokemon, eksperimen dengan konfigurasi terbaik ($\lambda_{am_2.0}$) belum diulang. Ada kemungkinan bahwa keragaman matchup yang lebih tinggi mempengaruhi kecepatan konvergensi atau jumlah state yang ditemukan.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Falah Andhesryo – NPM. 2306161990

IV.1.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- Kode/modul: `src/train.py`, `src/visualize_training.py`.
- Bagian arsitektur: Menyusun alur eksekusi *training* agar *agent* dapat menjalankan pertarungan secara berulang, mencatat perkembangan *win rate*, mengatur konfigurasi eksperimen, menyimpan hasil *Q-table*, serta memastikan hasil *training* dapat dianalisis melalui visualisasi nilai *Q* dan sebaran *state value*.
- Bagian analisis: Menganalisis hasil *training* berdasarkan perkembangan *win rate*, jumlah *Q-state* yang terbentuk, performa awal terhadap *random opponent*, serta visualisasi *Q-table* yang menunjukkan distribusi nilai *Q*, *state value*, dan distribusi aksi terbaik.
- Bagian laporan: Menyusun bagian pendahuluan terkait topik yang dipilih dan studi literatur, menganalisis visualisasi *Q-table* pada bagian hasil kualitatif, serta menyusun kesimpulan akhir laporan, pengecekan klaim bonus skor, dan arah pengembangan lanjutan.

IV.1.2 Pernyataan Penggunaan AI Assistant

- Tool yang dipakai: ChatGPT 5.5.
- Untuk bagian apa: *debugging* dan `src/train.py`.
- Tingkat ketergantungan: sedang (sekitar 40%).
- Pernyataan: Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.2 Bonifasius Raditya Pandu Hendrianto – NPM. 2306242350

IV.2.1 Komponen yang Dikerjakan

- **Kode/modul:** `q_learning_agent.py`, `evaluate.py`, `visualize_training.py`.
- **Bagian arsitektur:** Mengembangkan modul agen Q learning dengan *reward shaping* yang lebih detail pada `q_learning_agent.py`. Saya menambahkan komponen reward untuk damage, damage yang

diterima, KO, faint, status, penalti waktu, dan *potential-based reward* agar proses pembelajaran lebih informatif dan stabil. Selain itu, saya juga membantu memastikan pipeline evaluasi dan visualisasi terhubung dengan hasil training.

- **Bagian analisis:** Menganalisis perilaku agen selama training dan evaluasi berdasarkan metrik win rate, ukuran Q-table, serta komponen reward. Pada `evaluate.py`, saya memastikan model yang sudah dilatih dapat diuji secara konsisten terhadap lawan acak untuk membandingkan performa antar Q-table. Pada `visualize_training.py`, saya mendukung analisis hasil eksperimen melalui grafik kurva win rate, pertumbuhan Q-table, distribusi nilai Q, distribusi aksi terbaik, dan komposisi reward.
- **Bagian laporan:** Menyusun narasi hasil eksperimen dan interpretasi performa model, termasuk penjelasan pengaruh *reward shaping*, evaluasi terhadap lawan random, serta pembacaan grafik hasil training untuk menunjukkan perkembangan belajar agen dari waktu ke waktu.

IV.2.2 Pernyataan Penggunaan AI Assistant

- Tool yang dipakai: GPT 5.4.
- Untuk bagian apa: `src/evaluate.py`, `q_learning reward function`, dan `debugging`.
- Tingkat ketergantungan: sedang (sekitar 41%).
- Pernyataan: Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.3 Christian Hadiwijaya – NPM. 2306161952

IV.3.1 Komponen yang Dikerjakan

- **Kode/modul:** `q_learning_agent.py`, `train.py`, `teams.py`
- **Bagian arsitektur:** End-to-end flow training q-learning dengan reward sederhana, formatting teams polling, strategi environment (pemilihan team tetap, gen1)
- **Bagian analisis:** Memberikan saran peningkatan selanjutnya untuk diserahkan ke team. Salah satunya seperti, peningkatan pool pokemon lawan, penambahan reward variable agar bisa menghitung status moves dan pergantian pokemon.
- **Bagian laporan:** Bab 3.1 - 3.4

IV.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Claude Opus 4.6
- **Untuk bagian apa:** Generate pooling pokemon lawan [`teams.py`]. Belajar memahami cara kerja q-learning dan snippet code python

- **Tingkat ketergantungan:** 30% (Sangat mempercepat waktu walau bisa dilakukan secara manual dengan waktu lebih panjang)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.4 Jonathan Frederick Kosasih – NPM. 2306225981

IV.4.1 Komponen yang Dikerjakan

- **Kode/modul:** `src/teams.py`, `src/play_human.py`, `src/tune_hyperparams.py`, `src/plot_tuning.py`
- **Bagian arsitektur:** Mengembangkan *pool* Pokemon untuk tim lawan, menyusun konstruksi tim tetap untuk *agent*, mengatur pemilihan tim lawan secara acak, serta membuat logika simulasi interaksi pemain manusia dengan *agent*. Selain itu, saya juga membuat *script* `src/tune_hyperparams.py` dan `src/plot_tuning.py` untuk mendukung proses *hyperparameter tuning*.
- **Bagian analisis:** Mengoptimasi susunan tim Pokemon untuk *agent* dan variasi tim lawan pada proses *training* serta *evaluation*, sehingga model dihadapkan pada lawan dengan variasi *matchup* yang lebih tinggi.
- **Bagian laporan:** Menyusun laporan untuk bagian Bab 1 dan Bab 3, khususnya Subbab 3.5 hingga 3.7.

IV.4.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini Pro 3 dan Claude Sonnet 4.6.
- **Untuk bagian apa:** Membantu pembuatan *script* `src/play_human.py`, `src/tune_hyperparams.py`, `src/plot_tuning.py`, serta proses *debugging*.
- **Tingkat ketergantungan:** sedang (sekitar 40%), digunakan untuk mempercepat proses pengembangan dan penyelesaian masalah teknis.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

Berdasarkan rumusan masalah, implementasi, dan hasil eksperimen yang telah dilakukan, diperoleh kesimpulan sebagai berikut.

1. Terkait RM1, konsep *reinforcement learning* berhasil diterapkan dalam sistem pengambilan keputusan berbasis *Q learning* melalui siklus interaksi antara *agent* dan *environment*. Pada setiap giliran, *agent* mengamati *state*, memilih *action*, menerima *reward*, lalu memperbarui nilai pada *Q-table*. Implementasi ini dijalankan dengan konfigurasi awal 5000 *training battle*, 500 *evaluation battle*, *learning rate* $\alpha = 0.10$, *discount factor* $\gamma = 0.95$, dan *softmax temperature* $\lambda = 1.0$. Dengan demikian, proses pengambilan keputusan sekuensial dapat dimodelkan melalui pembaruan nilai *Q* berdasarkan pengalaman yang diperoleh selama *training*.
2. Terkait RM2, representasi *state*, *action*, dan *reward* pada implementasi *Q learning* telah dirancang sederhana tetapi tetap relevan dengan kebutuhan *Pokemon battle*. *State* direpresentasikan sebagai tuple 6 elemen, yaitu *HP bucket* Pokemon aktif milik *agent*, *HP bucket* Pokemon aktif lawan, serta tipe primer dan sekunder dari kedua Pokemon aktif. Nilai HP didiskretisasi ke dalam 10 *bucket* dengan rentang 0–9. *Action* dibatasi pada pemilihan *move* yang tersedia, yaitu maksimal 4 *move* per giliran. *Reward* terdiri atas *terminal reward* sebesar +100 untuk menang dan -100 untuk kalah, serta *intermediate reward* berbasis selisih fraksi HP dengan rentang sekitar -5 sampai +5 per giliran. Representasi ini membuat ruang keputusan cukup kecil untuk *tabular Q learning*, tetapi masih mampu menangkap informasi penting dalam pertarungan.
3. Terkait RM3, hasil eksperimen menunjukkan bahwa implementasi *Q learning* mampu membentuk strategi *agent* yang efektif pada skenario *Pokemon battle* melawan *random opponent*. Pada eksperimen baseline, *agent* memperoleh *evaluation win rate* sebesar 94,8% setelah 500 *evaluation battle*. Setelah dilakukan *hyperparameter tuning*, konfigurasi terbaik mencapai *evaluation win rate* sebesar 96,8%. Meskipun demikian, implementasi ini masih memiliki keterbatasan, yaitu belum adanya *switch Pokemon* sebagai bagian dari ruang *action*, belum digunakannya fitur status kondisi seperti *sleep* atau *paralysis* dalam *state*, serta evaluasi yang masih terbatas pada *random opponent*.

5.2 Klaim Bonus Skor

- ☒ **B1. Evaluasi Komparatif & Iterasi** → bukti pada Subbab 3.4 dan 3.5
- ☒ **B2. Dataset Mandiri** → bukti pada Subbab 3.1 + Lampiran B
- ☒ **B3. Analisis Etika, Bias, & Keterbatasan** → bukti pada Subbab 3.6 dan 3.7

5.3 Pekerjaan Lanjutan (*Future Work*)

1. Menambahkan mekanisme *switch Pokemon* sebagai bagian dari ruang *action*. Pada implementasi saat ini, *agent* hanya memilih *move* yang tersedia, sehingga belum dapat melakukan pergantian Pokemon secara strategis ketika berada pada kondisi *type disadvantage*. Pengembangan ini dapat dilakukan dengan memperluas ruang *action* agar mencakup pilihan *move* dan *switch*.
2. Memperluas representasi *state* dengan fitur status kondisi, seperti *sleep*, *paralysis*, *poison*, *burn*, dan *freeze*. Fitur ini penting karena status kondisi dapat memengaruhi kemampuan Pokemon untuk bergerak, menerima *damage*, atau bertahan dalam beberapa giliran berikutnya. Dengan penambahan fitur tersebut, *agent* diharapkan dapat membedakan kondisi Pokemon yang sehat dan Pokemon yang sedang terkena status.
3. Memperluas *custom opponent pool* dari 50 Pokemon Gen 1 ke seluruh 151 Pokemon Gen 1. Pengembangan ini bertujuan untuk menguji apakah *policy* yang dipelajari tetap stabil ketika variasi *matchup* meningkat. Evaluasi terhadap pool yang lebih luas juga dapat membantu mengukur kemampuan generalisasi *agent* terhadap lawan yang belum sering ditemui selama *training*.

DAFTAR PUSTAKA

- [1] GeeksforGeeks, “Reinforcement Learning,” GeeksforGeeks. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/what-is-reinforcement-learning/>. [Accessed: May 25, 2026].
- [2] AutoML.org, “Hyperparameter Tuning in Reinforcement Learning is Easy, Actually,” AutoML.org. [Online]. Available: <https://www.automl.org/hyperparameter-tuning-in-reinforcement-learning-is-easy-actually/>. [Accessed: May 25, 2026].
- [3] B. Jang, M. Kim, G. Harerimana, and J. W. Kim, “Q-Learning Algorithms: A Comprehensive Classification and Applications,” *IEEE Access*, vol. 7, pp. 133653–133667, 2019, doi: 10.1109/ACCESS.2019.2941229.
- [4] Park et al., “Distribution-Aware Reward: Reinforcement Learning over Predictive Distributions for LLM Regression,” arXiv. [Online]. Available: <https://arxiv.org/html/2605.20740v1>. [Accessed: May 25, 2026].
- [5] “Advances in deep reinforcement learning enable better predictions of human behavior in time-continuous tasks,” *PMC*. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12677501/>. [Accessed: May 25, 2026].
- [6] A. Kalose, “Optimal Battle Strategy in Pokemon using Reinforcement Learning,” Stanford University, 2018. [Online]. Available: <https://web.stanford.edu/class/aa228/reports/2018/final151.pdf>. [Accessed: May 25, 2026].

LAMPIRAN A

Berkas Metadata Proyek (JSON)

```
{
  {
    "kode_kelompok": "Rabu-15",
    "topik_pilihan": 5,
    "nama_topik": "Reinforcement Learning",
    "judul_proyek": "Implementasi Reinforcement Learning Menggunakan Q-learning pada Strategi Pertarungan Pokemon Battle",
    "abstrak_singkat": "Pertarungan Pokemon battle dimodelkan sebagai masalah pengambilan keputusan sekuensial menggunakan tabular Q-learning dengan eksplorasi softmax pada simulator Pokemon Showdown. Agen menggunakan fixed team Gen 1 OU berisi Alakazam, Snorlax, Tauros, Starmie, Exeggutor, dan Chansey, sementara lawan dipilih secara acak dari custom opponent pool berisi 50 Pokemon Gen 1. State direpresentasikan sebagai tuple diskret 6 elemen yang mencakup HP bucket dan tipe Pokemon aktif, action berupa pemilihan maksimal 4 move yang tersedia, dan reward menggunakan terminal reward serta modular reward shaping yang mencakup damage, damage taken, KO, faint, status condition, time penalty, dan potential-based reward. Pada baseline 8.000 training battle dan 500 evaluation battle, agen mencapai training win rate 86,8%, evaluation win rate 94,8%, dan menemukan 9.772 Q-table states. Setelah hyperparameter tuning, konfigurasi terbaik lam_2.0 dengan alpha=0.10, gamma=0.95, dan lambda=2.0 mencapai evaluation win rate 96,8%.",
    "metode_ai": [
      {
        "nama": "Tabular Q-learning",
        "peran": "utama",
        "varian": "Q-learning berbasis Q-table dictionary dengan state diskret 6 elemen dan action berupa indeks move 0-3",
        "catatan": "Algoritma utama untuk melatih agent memilih move terbaik berdasarkan nilai Q pada state pertarungan. Baseline menggunakan alpha=0.10, gamma=0.95, dan softmax lambda=1.0."
      },
      {
        "nama": "Softmax exploration",
        "peran": "strategi eksplorasi saat training",
        "varian": "Pemilihan action berbasis probabilitas softmax terhadap nilai Q yang dinormalisasi secara lokal",
        "catatan": "Digunakan agar agent tetap mengeksplorasi action alternatif selama training, tetapi tetap memberi probabilitas lebih tinggi pada action dengan nilai Q lebih baik. Tuning menunjukkan lambda=2.0 sebagai konfigurasi terbaik."
      },
      {
        "nama": "Greedy policy",
        "peran": "strategi evaluasi",

```

```

"varian": "Argmax terhadap nilai Q pada action yang valid di state saat ini"
,
"catatan": "Digunakan pada fase evaluation agar performa policy yang sudah
dipelajari dapat diukur tanpa eksplorasi."
},
{
"nama": "RandomPlayer",
"peran": "baseline opponent",
"varian": "Opponent non-learning dari poke-env yang memilih move secara acak
",
"catatan": "Digunakan sebagai lawan utama pada training dan evaluation.
Evaluasi terhadap RandomPlayer menjadi dasar metrik win rate proyek."
}
],
"frameworks": [
{
"nama": "Python",
"versi": "3.11",
"kegunaan": "Bahasa utama untuk implementasi training, evaluation, Q-
learning agent, visualisasi, hyperparameter tuning, dan human-vs-AI mode
"
},
{
"nama": "poke-env",
"versi": ">=0.15.0",
"kegunaan": "Interface Python untuk menghubungkan agent dengan Pokemon
Showdown melalui WebSocket, membaca state battle, dan mengeksekusi
action"
},
{
"nama": "NumPy",
"versi": ">=1.24.0",
"kegunaan": "Operasi numerik untuk Q-table, softmax probability computation,
action selection, dan pengolahan hasil eksperimen"
},
{
"nama": "Pokemon Showdown",
"versi": "local server",
"kegunaan": "Simulator battle Gen 1 OU sebagai environment reinforcement
learning dengan mekanika stokastik seperti accuracy, critical hit, dan
speed tie"
},
{
"nama": "Matplotlib",
"versi": "tidak dispesifikkan",
"kegunaan": "Visualisasi hasil hyperparameter tuning, kurva training,
distribusi nilai Q, state value, dan distribusi action terbaik"
},
{
"nama": "Node.js",
"versi": "tidak dispesifikkan",

```

```

    "kegunaan": "Menjalankan server lokal Pokemon Showdown sebagai environment
        battle"
    }
],
"datasets": [
    {
        "nama": "Custom Opponent Pool Pokemon Gen 1",
        "tipe": "dataset_mandiri",
        "sumber": "Custom opponent pool berisi 50 Pokemon Gen 1 yang disusun untuk
            membangkitkan tim lawan secara acak; Claude Opus 4.6 digunakan sebagai
            bantuan awal dalam pembuatan pool dan moveset",
        "url_sumber publik": "",
        "jumlah_sampel": 50,
        "jumlah_kelas": 0,
        "proses_akuisisi_mandiri": "Tim menggunakan custom opponent pool berisi 50
            Pokemon Gen 1 sebagai basis pembentukan tim lawan. Pada setiap battle, 6
            Pokemon diambil secara random sampling dari pool tersebut. Pool ini
            digunakan untuk memberi variasi matchup selama training dan evaluation.
            Claude Opus 4.6 digunakan sebagai alat bantu untuk menghasilkan
            referensi pool/moveset, sementara penyesuaian eksperimen dan integrasi
            ke kode dilakukan oleh tim.",
        "peran_di_proyek": "Menjadi sumber variasi lawan untuk training dan
            evaluation serta mendukung klaim bonus B2 sebagai dataset mandiri/custom
            opponent pool.",
        "spek_rl": {
            "state_space": "Tuple diskret 6 elemen: (player_hp_bucket, opp_hp_bucket
                , player_type_1, player_type_2, opp_type_1, opp_type_2). Secara
                teoritis  $10 \times 10 \times 15 \times 16 \times 15 \times 16 = 5.760.000$  kombinasi; baseline
                menemukan 9.772 state unik.",
            "action_space": "Discrete maksimal 4 action, yaitu memilih salah satu
                move yang tersedia pada giliran tersebut.",
            "reward_function": "Terminal reward +100 untuk menang dan -100 untuk
                kalah; intermediate modular reward terdiri atas damage reward, taken
                penalty, KO bonus, faint penalty, status bonus, time penalty, dan
                potential-based reward shaping yang di-clip ke [-50, +50].",
            "max_episode_steps": "Satu episode berlangsung hingga satu battle
                selesai.",
            "framework_env": "Pokemon Showdown melalui poke-env.",
            "modifikasi_tim": "Agent menggunakan fixed team Gen 1 OU; opponent team
                dibuat acak dari custom opponent pool 50 Pokemon Gen 1."
        }
    },
    {
        "nama": "Pokemon Showdown Gen 1 OU Battle Experience",
        "tipe": "environment_generated_experience",
        "sumber": "Interaksi online antara agent dan server lokal Pokemon Showdown
            melalui poke-env",
        "url_sumber publik": "https://github.com/smogon/pokemon-showdown",
        "jumlah_sampel": 0,
        "jumlah_kelas": 0,
        "proses_akuisisi_mandiri": "Data pengalaman tidak dikumpulkan sebagai
            dataset statis, tetapi dihasilkan selama agent melakukan battle berulang

```

```

        dengan opponent. Setiap state-action-reward transition menjadi sampel
        pembelajaran untuk memperbarui Q-table.",
    "peran_di_proyek": "Environment utama untuk training, evaluation,
        hyperparameter tuning, dan demo human-vs-AI.",
    "spek_rl": {
        "state_space": "State battle dari Pokemon Showdown diproses menjadi
            tuple diskret HP bucket dan tipe Pokemon aktif.",
        "action_space": "Move yang valid pada setiap turn, dipetakan ke indeks
            action 0-3.",
        "reward_function": "Reward dihitung dari hasil turn dan hasil akhir
            battle menggunakan terminal reward serta modular reward shaping.",
        "max_episode_steps": "Sampai battle selesai.",
        "framework_env": "poke-env wrapper untuk Pokemon Showdown WebSocket.",
        "modifikasi_tim": "Server lokal digunakan untuk format genlou; agent
            fixed team dan opponent random team dari custom opponent pool."
    }
},
    "metrik_utama": [
        "Evaluation win rate vs RandomPlayer (500 greedy evaluation battles)",
        "Training win rate selama 8.000 training battles",
        "Jumlah Q-table states yang ditemukan",
        "Training time dalam detik",
        "Perbandingan win rate terhadap paper acuan Kalose et al.",
        "Hasil hyperparameter tuning terhadap alpha, gamma, dan lambda",
        "Distribusi nilai Q, state value, dan distribusi action terbaik per state"
    ],
    "klaim_bonus": [
        "B1",
        "B2",
        "B3"
    ],
    "anggota": [
        {
            "nama": "Falah Andhesryo",
            "npm": "2306161990",
            "peran_utama": "Training Pipeline & Report Writer",
            "focus_area": [
                "Kode/modul: src/train.py",
                "Arsitektur: menyusun alur eksekusi training berulang",
                "Analisis: pencatatan win-rate dan visualisasi Q-table",
                "Laporan: pendahuluan, analisis Q-table, kesimpulan, klaim bonus, future
                    work"
            ]
        }
    ],
    "konsep_dikuasai_implementasi": [
        "Implementasi src/train.py: inisialisasi experiment, loop battle,
            logging win-rate, menyimpan Q-table",
        "Integrasi agen dengan simulator (poke-env) dan konfigurasi training/
            evaluation",
        "Mekanisme penyimpanan hasil training (file model / Q-table)",
        "Script evaluasi dan visualisasi hasil training (visualize_training.py)"
    ],

```

```

"konsep_dikuasai_teor": [
    "Tabular Q-learning: update rule dan konvergensi pada state diskret",
    "Perbedaan mode training vs evaluation dan greedy policy extraction",
    "Interpretasi metrik: training vs evaluation win-rate dan jumlah state"
],
"bagian_laporan": [
    "Bab 1: Pendahuluan & definisi masalah",
    "Bab IV: Pembagian tugas & deklarasi kontribusi individual",
    "Bab V: Kesimpulan & pekerjaan lanjutan"
],
"bagian_kode": [
    "src/train.py"
]
},
{
    "nama": "Bonifasius Raditya Pandu Hendrianto",
    "npm": "2306242350",
    "peran_utama": "RL Agent, Evaluator & Visualization Engineer",
    "focus_area": [
        "Kode/modul: src/q_learning_agent.py, src/evaluate.py, src/visualize_training.py",
        "Arsitektur: implementasi reward shaping modular",
        "Analisis: visualisasi Q-table dan interpretasi performa"
    ]
},
"konsep_dikuasai_implementasi": [
    "Implementasi q_learning_agent.py: Q-table dictionary, update rule, action selection (softmax/greedy)",
    "Implementasi fungsi reward modular: damage, taken, KO, faint, status, time penalty, potential-based reward",
    "Script evaluasi dan visualisasi hasil training (evaluate.py, visualize_training.py)"
],
"konsep_dikuasai_teor": [
    "Bellman update dan stabilitas pembelajaran pada tabular Q-learning",
    "Konsep reward shaping dan potential-based shaping",
    "Metode evaluasi: training vs evaluation win-rate dan risiko single-run"
],
"bagian_laporan": [
    "Bab 3: Implementasi & hasil eksperimen",
    "Subbab terkait reward shaping, evaluasi, dan visualisasi"
],
"bagian_kode": [
    "src/q_learning_agent.py",
    "src/evaluate.py",
    "src/visualize_training.py"
]
},
{
    "nama": "Christian Hadiwijaya",
    "npm": "2306161952",
    "peran_utama": "Q-learning Support & Experiment Design Contributor",
    "focus_area": [

```

```

        "Kode/modul: src/q_learning_agent.py, src/train.py, src/teams.py",
        "Arsitektur: end-to-end training flow dan formatting team pool",
        "Analisis: saran pengembangan reward variable dan perluasan action"
    ],
    "konsep_dikuasai_implementasi": [
        "Struktur flow training Q-learning (state encoding sampai update Q)",
        "Pembuatan dan formatting teams.py (custom opponent pool)",
        "Integrasi fixed team agent dan random opponent sampling"
    ],
    "konsep_dikuasai_teoris": [
        "Representasi state diskret (HP bucket, tipe) dan implikasinya terhadap ukuran Q-table",
        "Trade-off desain: membatasi action (move only) vs menambahkan switch",
        "Peran reward variable untuk menangani status condition"
    ],
    "bagian_laporan": [
        "Bab 3.1: Dataset & pra-pemrosesan",
        "Bab 3.2: Konfigurasi eksperimen",
        "Bab 3.3: Metrik evaluasi",
        "Bab 3.4: Hasil kuantitatif"
    ],
    "bagian_kode": [
        "src/q_learning_agent.py",
        "src/train.py",
        "src/teams.py"
    ]
},
{
    "nama": "Jonathan Frederick Kosasih",
    "npm": "2306225981",
    "peran_utama": "Opponent Pool, Human Interface & Hyperparameter Tuning",
    "focus_area": [
        "Kode/modul: src/teams.py, src/play_human.py, src/tune_hyperparams.py, src/plot_tuning.py",
        "Arsitektur: pembangunan pool lawan dan human-vs-AI mode",
        "Analisis: hyperparameter tuning dan variasi matchup"
    ],
    "konsep_dikuasai_implementasi": [
        "Pembuatan custom opponent pool dan sampling tim lawan (teams.py)",
        "Implementasi mode human-vs-AI (play_human.py)",
        "Script tuning dan plotting untuk hyperparameter (tune_hyperparams.py, plot_tuning.py)"
    ],
    "konsep_dikuasai_teoris": [
        "Pengaruh komposisi tim terhadap win-rate dan generalisasi policy",
        "Sensitivitas hyperparameter (alpha, gamma, lambda)",
        "Metode evaluasi demonstratif (human-vs-AI) vs pengukuran kuantitatif"
    ],
    "bagian_laporan": [
        "Bab 1: konteks & topik",
        "Bab 3.5: Hyperparameter tuning",
        "Bab 3.6: Hasil kualitatif & error analysis",

```



```

        "Bab 3.7: Pembahasan"
    ],
    "bagian_kode": [
        "src/teams.py",
        "src/play_human.py",
        "src/tune_hyperparams.py",
        "src/plot_tuning.py"
    ]
},
    "tautan": {
        "github": "https://github.com/Tianrider/Qlearning-pokemon-battle/tree/main",
        "colab": "",
        "dataset_mandiri": "https://github.com/Tianrider/Qlearning-pokemon-battle/blob/main/src/teams.py",
        "video_demo": "https://youtu.be/FM1apJvwk14"
    },
    "ai_assistant_usage": {
        "digunakan": true,
        "tools": [
            "ChatGPT 5.5",
            "GPT 5.4",
            "Claude Opus 4.6",
            "Claude Sonnet 4.6",
            "Gemini Pro 3"
        ],
        "bagian": [
            "Membantu debugging training pipeline dan src/train.py",
            "Membantu pengembangan src/evaluate.py, reward function pada q_learning_agent.py, dan visualize_training.py",
            "Membantu pembuatan custom opponent pool dan referensi moveset Pokemon Gen 1",
            "Membantu pembuatan src/play_human.py, src/tune_hyperparams.py, dan src/plot_tuning.py",
            "Membantu perapian narasi laporan, studi literatur, interpretasi hasil, kesimpulan, klaim bonus, dan future work"
        ],
        "estimasi_persentase": 38
    }
}

```

LAMPIRAN B

Tautan Repositori & Dataset

GitHub repo: <https://github.com/Tianrider/Qlearning-pokemon-battle/tree/main>

Dataset mandiri: <https://github.com/Tianrider/Qlearning-pokemon-battle/blob/main/src/teams.py>

Video demo: <https://youtu.be/FM1apJvwk14>

Status akses: repositori publik / Colab dengan permission “anyone with the link can view”. Sudah diverifikasi terbuka pada 19 Mei 2026.

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

C.1 Brief Explanation. *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* [Name of course lecturer], Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* [principal investigator's email]. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 Data Collected. Final report (PDF) and `metadata.json` file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 Data Management. **Participant names and student IDs (NPMs) will be stored anonymously** — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 Participant Rights. (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] – [Name] – [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 Individual Consent. Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent — Member 1

Full name : Falah Andhesryo
Student ID (NPM) : 2306161990
Email : falahand@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☒ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



()

Date: 25 May 2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 2

Full name : Bonifasius Raditya Pandu Hendrianto
Student ID (NPM) : 2306242350
Email : radityahendrianto@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☒ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



()

Date: 25 May 2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 3

Full name : Christian Hadiwijaya
Student ID (NPM) : 2306161952
Email : hadiwijayachristian7@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☒ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



()

Date: 25 May 2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 4

Full name : Jonathan Frederick Kosasih
Student ID (NPM) : 2306225981
Email : jonathankosasih@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☒ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



()

Date: 25 May 2026

Witness / researcher's signature

()

Date: